

รายงานโครงงานสอบกลางภาค (Midterm Examination)

วิชา การวิเคราะห์ข้อมูลเชิงสำรวจ (Exploratory Data Analysis - EDA)

เรื่อง: การวิเคราะห์เชิงสำรวจ การแสดงผลด้วยภาพ และการเตรียมคุณลักษณะของ
ข้อมูล Scopus 10 สาขาวิชาสำหรับ Machine Learning

อาจารย์ผู้สอน: ผู้ช่วยศาสตราจารย์ ดร.โอฬาริก สุรินทร์ตะ

รายชื่อสมาชิกกลุ่มผู้จัดทำ:

1. นายณัฐวุฒิ พละศักดิ์ รหัสนิสิต 67011211017
2. นายพงศกร ไชยวงศ์ รหัสนิสิต 67011211039
3. นายอนุรักษ์ งามจันอัด รหัสนิสิต 67011211062
4. นายปภักร กุศล รหัสนิสิต 67011211035

ภาคการศึกษาที่ 1 ปีการศึกษา 2569

มหาวิทยาลัยมหาสารคาม

บทสรุปผู้บริหาร (Executive Summary)

รายงานฉบับนี้นำเสนอกระบวนการวิเคราะห์ข้อมูลเชิงสำรวจ (Exploratory Data Analysis: EDA) และการเตรียมความพร้อมของข้อมูลงานวิจัยทางวิทยาการคอมพิวเตอร์จากฐานข้อมูลวิชาการ Scopus จำนวนทั้งสิ้น 10 สาขาวิชา (Subject Areas) เพื่อรองรับการนำไปเรียนรู้ต่อยอดด้วยโมเดลการเรียนรู้ของเครื่อง (Machine Learning) และระบบประมวลผลภาษาธรรมชาติ (NLP) โดยกลุ่มผู้จัดทำได้รวบรวมข้อมูลดิบจำนวน 7,280 รายการ (เฉลี่ยสาขาละ 728 รายการ) และดำเนินการตรวจสอบคุณภาพข้อมูลตามโจทย์ที่ได้รับมอบหมายอย่างเคร่งครัด

ผลการทำความสะอาดข้อมูล (Data Cleaning) พบความผิดปกติของข้อมูล ได้แก่ บทความที่มีการปรากฏซ้ำซ้อนข้ามสาขาวิชาจำนวน 178 รายการ, บทความที่ใช้ภาษาอื่นที่ไม่ใช่ภาษาอังกฤษจำนวน 25 รายการ, บทความที่ขาดบทคัดย่อจำนวน 30 รายการ, และบทความนอกบริบทวิทยาการคอมพิวเตอร์ที่หลุดเข้ามาจากการสืบค้น (เช่น อสังหาริมทรัพย์ในดูไบ การจัดการโรงแรม ทันตกรรม และการเกษตร) จำนวน 59 รายการ หลังการขจัดสิ่งเจือปนทั้งหมด คงเหลือชุดข้อมูลสะอาดพร้อมใช้งานจำนวน 6,988 รายการ ซึ่งทุกสาขาวิชาที่มีจำนวนบทความเกินเกณฑ์ขั้นต่ำ 600 รายการอย่างครบถ้วน

ในส่วนของการสร้างการแสดงผลด้วยภาพแบบโต้ตอบ (Interactive Data Visualization) กลุ่มนิสิตได้พัฒนาเว็บแอปพลิเคชันรูปแบบ Single Page Dashboard จำนวน 5 มุมมองหลัก ได้แก่ เครือข่ายคำสำคัญที่ปรากฏร่วมกัน (Keyword Co-occurrence Network), คลาวด์คำสำคัญเชิงโต้ตอบ (Interactive Word Cloud), แผนภูมิความร้อนความสัมพันธ์ข้ามสาขา (Cross-Subject Overlap Heatmap), จตุภาควิเคราะห์การเติบโตเชิงยุทธศาสตร์ (Strategic Topic Growth Quadrant), และระบบสืบค้นบทความเชิงลึก (Scopus Document Explorer) ทั้งหมดทำงานบนสถาปัตยกรรมที่สามารถเปิดใช้งานได้บนเว็บเบราว์เซอร์ทันทีโดยไม่ต้องติดตั้งโปรแกรมเพิ่มเติม

สำหรับการเตรียมข้อมูลเพื่อสร้าง Feature Vector และ Text Embedding ได้ทำการรวมข้อมูล 4 คอลัมน์สำคัญ ได้แก่ Title, Abstract, Author Keywords และ Index Keywords เข้าด้วยกัน พร้อมจำลองและวิเคราะห์ข้อจำกัดความยาวโทเค็น (Token Limit 512 โทเค็น) ของโมเดลเฉพาะทางด้านวิทยาศาสตร์ SPECTER2 และทำการปรับขนาดเวกเตอร์ด้วย L2 Normalization เพื่อให้ได้เวกเตอร์มิติ 768 ที่มีความพร้อมสูงสุดสำหรับงานจำแนกสาขาวิชา (Classification) และการจัดกลุ่มบทความตามความหมาย (Semantic Clustering)

ส่วนที่ 1: กระบวนการทำ Exploratory Data Analysis (EDA) และการทำความสะอาดข้อมูล

1.1 การสืบค้นและรวบรวมข้อมูลจากฐานข้อมูล Scopus

กลุ่มผู้จัดทำได้ดำเนินการเข้าสู่ฐานข้อมูล Scopus (scopus.com) ภายใต้สิทธิการเข้าถึงของมหาวิทยาลัย โดยกำหนดขอบเขตการสืบค้นในกลุ่มสาขาวิชาหลักด้าน Computer Science เพื่อเลือกดึงข้อมูลบทความวิจัยใน 10 สาขาวิชาย่อย (Subject Areas) ตามที่กำหนดในข้อกำหนดการสอบ ดังต่อไปนี้:

- 1. Hardware and Architecture: จำนวนข้อมูลดิบที่ดึงมา 739 รายการ, หลังทำความสะอาดเหลือ 702 รายการ
- 2. Artificial Intelligence: จำนวนข้อมูลดิบที่ดึงมา 733 รายการ, หลังทำความสะอาดเหลือ 696 รายการ
- 3. Software: จำนวนข้อมูลดิบที่ดึงมา 731 รายการ, หลังทำความสะอาดเหลือ 704 รายการ
- 4. Information Systems: จำนวนข้อมูลดิบที่ดึงมา 730 รายการ, หลังทำความสะอาดเหลือ 700 รายการ
- 5. Signal Processing: จำนวนข้อมูลดิบที่ดึงมา 728 รายการ, หลังทำความสะอาดเหลือ 702 รายการ
- 6. Computer Networks and Communications: จำนวนข้อมูลดิบที่ดึงมา 727 รายการ, หลังทำความสะอาดเหลือ 694 รายการ
- 7. Human-Computer Interaction: จำนวนข้อมูลดิบที่ดึงมา 727 รายการ, หลังทำความสะอาดเหลือ 697 รายการ
- 8. Computer Vision and Pattern Recognition: จำนวนข้อมูลดิบที่ดึงมา 725 รายการ, หลังทำความสะอาดเหลือ 697 รายการ
- 9. Computer Graphics and Computer-Aided Design: จำนวนข้อมูลดิบที่ดึงมา 721 รายการ, หลังทำความสะอาดเหลือ 698 รายการ
- 10. Computational Theory and Mathematics: จำนวนข้อมูลดิบที่ดึงมา 719 รายการ, หลังทำความสะอาดเหลือ 698 รายการ

การส่งออกข้อมูลจาก Scopus กำหนดให้ครอบคลุมคอลัมน์มาตรฐานครบทุกมิติ ได้แก่ ข้อมูลการอ้างอิง (Authors, Title, Year, EID, Source title, Cited by, DOI), ข้อมูลบรรณานุกรม (Affiliations, Publisher, ISSN, Language), ข้อมูลเนื้อหาและคำสำคัญ (Abstract, Author Keywords, Index Keywords) และข้อมูลการสนับสนุนทุนวิจัย รวมทั้งสิ้นกว่า 40 คอลัมน์

1.2 การตรวจสอบคุณภาพและการทำความสะอาดข้อมูล (Data Cleaning Pipeline)

จากการสำรวจโครงสร้างข้อมูลดิบเบื้องต้น พบว่าข้อมูลทางวิชาการที่ได้จากการสืบค้นด้วยคำสำคัญมักมีความคลาดเคลื่อนและสิ่งเจือปน กลุ่มผู้จัดทำจึงได้ออกแบบกระบวนการทำความสะอาดข้อมูลตามขั้นตอนและเงื่อนไขของอาจารย์ผู้สอนอย่างเป็นระบบ:


- 1) การตรวจและกำจัดข้อมูลซ้ำซ้อน (Deduplication): ตามเงื่อนไขที่อาจารย์ระบุไว้ บทความวิจัยหนึ่งเรื่องควรจัดอยู่ใน Subject Area ที่เหมาะสมเพียงสาขาเดียวเท่านั้น หากพบบทความเรื่องเดียวกันปรากฏซ้ำข้ามสาขา (เช่น ปรากฏทั้งใน Artificial Intelligence และ Software) ระบบจะตรวจจับด้วยชื่อบทความ (Title) และรหัสระบุวัตถุดิจิทัล (DOI) โดยดำเนินการคัดเลือกให้อยู่ในสาขาที่มีความเกี่ยวข้องสูงสุดเพียงรายการเดียว และตัดรายการซ้ำออก ซึ่งในขั้นตอนนี้สามารถกำจัดบทความซ้ำได้ทั้งสิ้น 178 รายการ
- 2) การกรองบทความภาษาต่างประเทศ (Language Filter): เนื่องจากโมเดลการเรียนรู้ทางภาษา และ Text Embedding ที่เลือกใช้ (เช่น SPECTER2 และ SciBERT) ได้รับการฝึกฝนบนชุดข้อมูลภาษาอังกฤษ ดังนั้นบทความที่ระบุคอลัมน์ 'Language of Original Document' เป็นภาษาอื่นที่ไม่ใช่ภาษาอังกฤษ (เช่น สเปน จีน ฝรั่งเศส หรือเยอรมัน) จำนวน 25 รายการ จึงถูกคัดกรองออกจากชุดข้อมูล เพื่อป้องกันสัญญาณรบกวนในการสร้างเวกเตอร์ความหมาย
- 3) การคัดกรองบทความที่ขาดบทคัดย่อ (Missing Abstracts Filter): บทความที่ขาดบทคัดย่อเป็นข้อมูลส่วนหลักที่บรรณารักษ์สำคัญของระเบียบวิธีและผลการวิจัย บทความที่มีค่าว่างในคอลัมน์ Abstract หรือมีความยาวข้อความน้อยกว่า 40 ตัวอักษร (เช่น บทความประเภท Editorial, Correction หรือบทคัดย่อที่ไม่สมบูรณ์) จำนวน 30 รายการ ได้รับการคัดออกจากการวิเคราะห์
- 4) การตรวจจับและขจัดบทความที่ไม่เกี่ยวข้อง (Irrelevant Domain Articles Filter): ปัญหาสำคัญที่มักพบในฐานข้อมูล Scopus คือการสืบค้นคำสำคัญทางคอมพิวเตอร์ที่ไปตรงกับงานวิจัยในศาสตร์อื่น เช่น การศึกษาดัชนีราคาอสังหาริมทรัพย์ (Dubai property price index), ประสิทธิภาพการ

จัดการโรงแรมและการท่องเที่ยว (Tourism management), การประเมินรากฟันเทียมไททาเนียม (Dental implants), และการประเมินผลผลิตข้าวสาลีฤดูหนาว (Winter wheat crop yield) ซึ่งหลุดเข้ามาในผลการค้นหา กลุ่มผู้จัดทำได้ใช้การตรวจจับด้วยรูปแบบคำค้นเฉพาะทางของโดเมนที่ไม่เกี่ยวข้องและคัดออกได้จำนวน 59 รายการ

1.3 สรุปผลการทำความสะอาดข้อมูล

ตารางที่ 1 แสดงสรุปจำนวนรายการในแต่ละขั้นตอนของการทำความสะอาดข้อมูล:

ขั้นตอนการประมวลผลข้อมูล	จำนวนที่ถูกคัดออก (รายการ)	คงเหลือในชุดข้อมูล (รายการ)
ชุดข้อมูลดิบที่ดาวน์โหลดจาก Scopus	—	7,280
การตัดบทความซ้ำซ้อนซ้ำม สาขาวิชา (Deduplication)	178	7,102
การกรองบทความ ภาษาต่างประเทศที่ไม่ใช่ ภาษาอังกฤษ	25	7,077
การคัดกรองบทความที่ไม่มี บทคัดย่อ (Missing Abstracts)	30	7,047
การขจัดบทความนอกบริบททาง คอมพิวเตอร์ (Domain Filter)	59	6,988




รูปที่ 1: การเปรียบเทียบจำนวนบทความดิบและบทความสะอาดใน 10 สาขาวิชาของ Scopus


1.4 สถิติเชิงพรรณนาที่สำคัญจากการสำรวจข้อมูล (Exploratory Data Insights)

จากการสำรวจชุดข้อมูลสะอาดจำนวน 6,988 รายการ พบลักษณะทางสถิติที่สำคัญดังนี้:

- แนวโน้มปีที่ตีพิมพ์: งานวิจัยมีการกระจายตัวตั้งแต่ปี 2020 ถึง 2026 โดยมีสัดส่วนสูงสุดในช่วงปี 2023–2024 (ปี 2023 มี 1,406 รายการ และปี 2024 มี 1,576 รายการ) ซึ่งสะท้อนถึงการเติบโตอย่างก้าวกระโดดของงานวิจัยด้าน Generative AI, Large Language Models และระบบประมวลผลประสิทธิภาพสูงในช่วงหลังวิกฤตโควิด-19
- สถิติการอ้างอิง (Citations): บทความในชุดข้อมูลมีจำนวนการอ้างอิงเฉลี่ย 6.09 ครั้ง ค่ามัธยฐานอยู่ที่ 3.0 ครั้ง และมีค่าการอ้างอิงสูงสุดถึง 208 ครั้ง การกระจายตัวของการอ้างอิงเป็นไปตามลักษณะ Power-Law Distribution หรือ Long-Tail ซึ่งบทความส่วนใหญ่ได้รับการอ้างอิงในระดับปานกลาง ในขณะที่บทความบุกเบิกในกลุ่ม Deep Learning และ Computer Vision ได้รับการอ้างอิงสูงอย่างมีนัยสำคัญ



รูปที่ 2: แนวโน้มจำนวนบทความที่ตีพิมพ์ในแต่ละปี (พ.ศ. 2563 - 2569 / ค.ศ. 2020 - 2026)



รูปที่ 3: แหล่งตีพิมพ์ชั้นนำ (Top Journals) และการกระจายตัวของจำนวนการอ้างอิง (Citations)

ส่วนที่ 2: การสร้างและการแปลความหมาย Data Visualization

เพื่อตอบสนองต่อโจทย์การเรียนรู้ที่ต้องการให้มองเห็นโครงสร้างความสัมพันธ์ของข้อมูลที่ซ่อนอยู่ในไฟล์ Scopus กลุ่มผู้จัดทำได้ออกแบบและพัฒนา Interactive Data Visualization ขึ้นบนเว็บเบราว์เซอร์ โดยอ้างอิงมาตรฐานจากตัวอย่างของอาจารย์ผู้สอน พร้อมทั้งเสริมขีดความสามารถในการโต้ตอบ โดยมีรายละเอียดของ Visualization แต่ละตัวและความสัมพันธ์กับข้อมูลดังนี้:

2.1 Keyword Co-occurrence Network (เครือข่ายความสัมพันธ์คำสำคัญ)

เครือข่ายคำสำคัญที่ปรากฏร่วมกันเป็นเทคนิคการวิเคราะห์เชิงโครงสร้าง (Structural Network Analysis) ที่มีวัตถุประสงค์เพื่อศึกษาว่า ในแวดวงวิทยาการคอมพิวเตอร์ หัวข้อวิจัยใดมักถูกหยิบยกขึ้นมาศึกษาควบคู่กัน โดยหลักการทางคณิตศาสตร์และองค์ประกอบของกราฟมีความสัมพันธ์กับข้อมูล ดังนี้:

- **โหนด (Nodes):** แทนคำสำคัญทางวิชาการ (Author Keywords และ Index Keywords) โดยขนาดรัศมีของโหนด ($r = 6 + 1.6\sqrt{DF}$) แปรผันตรงตามจำนวนบทความวิจัยที่ปรากฏคำสำคัญนั้น (Document Frequency)
- **เส้นเชื่อม (Edges):** แทนการปรากฏร่วมกันของคำสำคัญสองคำภายในบทความวิจัยเรื่องเดียวกัน โดยความหนาของเส้นแปรผันตามน้ำหนัก (w) ซึ่งคำนวณจากจำนวนบทความที่มีคำสำคัญทั้งสองปรากฏพร้อมกัน ช่วยให้ผู้ใช้วิเคราะห์เห็นแกนหลักของการเชื่อมโยงองค์ความรู้
- **การจัดกลุ่มด้วยสี (Thematic Clusters):** ประยุกต์ใช้อัลกอริทึม Modularity Maximization ในการตรวจจับกลุ่มชุมชน (Community Detection) แบ่งคำสำคัญออกเป็น 5 คลัสเตอร์หลัก ได้แก่ (1) AI & Large Models, (2) Networks & Cloud, (3) Computer Vision, (4) HCI & UI/UX, และ (5) Software Architecture หรือสามารถสลับเป็นโหมด Average Publication Year เพื่อดูว่าคำสำคัญใดเป็นหัวข้อเก่าหรือใหม่
- **ฟังก์ชันปฏิสัมพันธ์:** ผู้ใช้สามารถปรับเกณฑ์ Document Frequency ขึ้นต่ำเพื่อกรองโหนดที่ไม่สำคัญออก, ซูมและเลื่อนกราฟ (Zoom/Pan), และเมื่อคลิกที่โหนดใดๆ ระบบจะแสดงรายการคำสำคัญที่ปรากฏร่วมกันบ่อยที่สุด พร้อมเปิดดูรายชื่อบทความและบทคัดย่อจริงที่อยู่เบื้องหลังได้ทันที


2.2 Interactive Keyword Word Cloud (คลาวด์คำสำคัญเชิงโต้ตอบ)

Word Cloud แบบโต้ตอบทำหน้าที่สรุปความหนาแน่นเชิงความถี่ของคำสำคัญ (Lexical Density) ในภาพรวม โดยขนาดของตัวอักษรสะท้อนถึงจำนวนเอกสารวิจัย และสีของตัวอักษรถูกจัดหมวดหมู่ตาม

Thematic Clusters ความสัมพันธ์กับข้อมูลคือการเปิดโอกาสให้ผู้ใช้สามารถเลือกดูตามปีที่ตีพิมพ์ (Publication Year) ตั้งแต่ปี 2020 ถึง 2026 เพื่อสังเกตการเปลี่ยนแปลงของคำศัพท์สำคัญ เช่น ในช่วงปี 2020–2021 คำว่า 'convolutional neural networks' และ 'wireless sensor networks' มีขนาดเด่นชัด ขณะที่ในปี 2024–2026 คำว่า 'large language models', 'transformers' และ 'prompt engineering' ขยายขนาดขึ้นอย่างก้าวกระโดด

2.3 Cross-Subject Topic Overlap Heatmap (การถ่ายทอดองค์ความรู้ข้ามสาขาวิชา)

แผนภูมิความร้อนแสดงความสัมพันธ์ข้ามสาขาถูกสร้างขึ้นเพื่อทดสอบสมมติฐานการผสมผสานศาสตร์ (Interdisciplinary Integration) โดยแถวในแนวตั้งแทน Subject Area ทั้ง 10 สาขา และคอลัมน์ในแนวนอนแทนคำสำคัญยอดนิยม 12 อันดับแรก ความเข้มของสีสะท้อนถึงจำนวนบทความในสาขานั้นๆ ที่หยิบยกคำสำคัญดังกล่าวไปใช้ ผลการวิเคราะห์พบว่า คำสำคัญในกลุ่ม 'deep learning' และ 'machine learning' มีการกระจายตัวข้ามสาขาอย่างกว้างขวาง โดยไม่ได้จำกัดอยู่เพียงสาขา Artificial Intelligence เท่านั้น แต่ยังถูกนำไปใช้อย่างหนาแน่นใน Computer Vision, Signal Processing, Computer Networks, และ Software Engineering แสดงให้เห็นว่า AI ได้กลายสภาพเป็นเครื่องมือพื้นฐาน (General-Purpose Technology) ของทุกสาขาในปัจจุบัน



รูปที่ 4: แผนภูมิความร้อนแสดงการปรากฏของคำสำคัญข้าม 10 สาขาวิชา (Cross-Subject Heatmap)


2.4 Strategic Topic Growth Quadrant (จุดภาควิเคราะห์การเติบโตเชิงยุทธศาสตร์)

เพื่อตอบสนองต่อการวิเคราะห์แนวโน้มในอนาคต กลุ่มผู้จัดทำได้สร้างกราฟวิเคราะห์ 4 จุดภาค โดยคำนวณอัตราการเติบโตเชิงสัมพัทธ์ของคำสำคัญ ผ่านตัวชี้วัด Normalized Prevalence Growth Score (\$G\$) ซึ่งนิยามโดย:

$$G = \log_2((\text{Recent_docs} / r\text{Total} + 0.001) / (\text{Prior_docs} / p\text{Total} + 0.001))$$

โดย Recent_docs คือจำนวนบทความในช่วงปีล่าสุด (2024–2026) และ Prior_docs คือจำนวนบทความในช่วงก่อนหน้า (2020–2023) นำมาพล็อตเทียบกับปริมาณบทความจริงในช่วงล่าสุด (Recent Volume) บนแกน Y ทำให้สามารถแบ่งหัวข้อวิจัยออกเป็น 4 จุดภาคที่มีความสัมพันธ์กับข้อมูลอย่างชัดเจน:

- **1. High-Volume Emerging Topics (จุดภาคขวาบน):** หัวข้อที่มีปริมาณบทความสูงและมีอัตราการเติบโตเป็นบวกอย่างต่อเนื่อง เช่น Large Language Models, Transformers, Foundation Models และ Edge Computing ซึ่งเป็นกระแสหลักที่กำลังขับเคลื่อนอุตสาหกรรม
- **2. Established Topics (จุดภาคซ้ายบน):** หัวข้อหลักที่มีปริมาณบทความสูงแต่มีอัตราการเติบโตที่เริ่มทรงตัวหรือชะลอตัวลง เช่น Neural Networks, Cloud Computing, Wireless Networks และ Pattern Recognition ซึ่งถือเป็นองค์ความรู้พื้นฐานที่อิ่มตัวแล้ว
- **3. Emerging Niche Topics (จุดภาคขวาล่าง):** หัวข้อเกิดใหม่เฉพาะทางที่มีอัตราการเติบโตสูงมาก แม้ปริมาณบทความจะยังไม่มากนัก เช่น Prompt Engineering, Contrastive Learning, Explainable AI, และ Neuromorphic Computing ซึ่งมีศักยภาพในการขยับขึ้นเป็นกระแสหลักในอนาคต
- **4. Declining or Stable Niche Topics (จุดภาคซ้ายล่าง):** หัวข้อเฉพาะทางที่มีอัตราการเติบโตลดลงและปริมาณบทความจำกัด เช่น Shader Programming, Microprocessor Architecture แบบดั้งเดิม, และ Formal Automata Verification



รูปที่ 5: แผนภาพจุดภาควิเคราะห์การเติบโตของหัวข้อวิจัย (Strategic Topic Growth Quadrant)

2.5 Scopus Document Explorer (ระบบสำรวจบทความแบบโต้ตอบ)

มุมมองที่ 5 ในแดชบอร์ดคือระบบสืบค้นบทความจริง (Document Explorer) ที่เชื่อมโยงบทความและข้อมูลทางบรรณานุกรมเข้ากับผลการวิเคราะห์ ผู้ใช้สามารถสืบค้นด้วยข้อความอิสระ กรองตามสาขาวิชา และเรียงลำดับตามจำนวนการอ้างอิงหรือปีที่ตีพิมพ์ พร้อมเปิดหน้าต่าง Modal เพื่ออ่านบทความฉบับเต็มและเข้าถึงลิงก์ DOI ของเอกสารต้นฉบับได้ทันที

ส่วนที่ 3: การเตรียมข้อมูลและการสร้าง Text Embedding / Feature Vector สำหรับ Machine Learning

3.1 การบูรณาการฟิลด์ข้อความ (Text Concatenation Strategy)

ในการเตรียมข้อมูล Scopus เพื่อนำไปป้อนเข้าสู่โมเดล Machine Learning หรือ Deep Learning ข้อมูลที่กระจัดกระจายอยู่ในคอลัมน์ต่างๆ จำเป็นต้องได้รับการจัดโครงสร้างเป็นข้อความประโยคเดียว (Single Structured Document Text) เพื่อรักษาบริบทและบทบาททางความหมายของแต่ละองค์ประกอบ โดยกลุ่มนิสิตได้ใช้ฟังก์ชันการรวมข้อความตามแนวทางในสมุดงาน Colab ของอาจารย์ ดังนี้:

```
def combine_text(row):
    text_parts = []
    if row['title']: text_parts.append(f"Title: {row['title']}")
    if row['abstract']: text_parts.append(f"Abstract: {row['abstract']}")
    if row['author_keywords']: text_parts.append(f"Author keywords: {row['author_keywords']}")
    if row['index_keywords']: text_parts.append(f"Index keywords: {row['index_keywords']}")
    return '\n'.join(text_parts)
```

เหตุผลสำคัญในการใส่คำนำหน้าระบุประเภทข้อมูล (เช่น 'Title:', 'Abstract:', 'Author keywords:') คือการช่วยให้โมเดลการเรียนรู้ทางภาษาสามารถจำแนกความสำคัญของส่วนต่างๆ ได้ โดย Title บรรจุแก่นหลักของบทความ Abstract บรรจุบริบทและผลการทดลองอย่างละเอียด ขณะที่ Keywords บรรจุคำศัพท์เฉพาะทางระดับสูง

3.2 ข้อจำกัดความยาวโทเค็นและการตัดข้อความ (Token Truncation at 512 Tokens)

โมเดลจำพวก Transformer สำหรับงานวิจัยทางวิทยาศาสตร์ เช่น SPECTER2 ('allenai/specter2_base') และ SciBERT มีข้อจำกัดทางสถาปัตยกรรมด้านตำแหน่ง (Positional Embeddings) ที่รับความยาวข้อความสูงสุดได้ไม่เกิน 512 โทเค็น จากการสำรวจทางสถิติในชุดข้อมูล สะอาดจำนวน 6,988 รายการ พบว่า:

- ความยาวข้อความรวมเฉลี่ยอยู่ที่ 169.9 โทเค็น
- ค่ามัธยฐานอยู่ที่ 159.9 โทเค็น
- มีบทความประมาณ 0.0% ที่มีความยาวเกินกว่า 512 โทเค็นและจำเป็นต้องถูกตัด (Truncation)

ผลกระทบจากการตัดข้อความที่เกิน 512 โทเค็น: เนื่องจากโครงสร้างการรวมข้อความได้วาง 'Author keywords' และ 'Index keywords' ไว้ที่ส่วนท้ายสุดของข้อความ หากบทความใดมี Abstract ที่ยาวมาก คำสำคัญบางส่วนอาจถูกตัดทิ้งไม่ถูกนำไปคำนวณในชั้น Transformer อย่างไรก็ตาม ในทางปฏิบัติ Abstract ส่วนต้นและชื่อเรื่อง (Title) มีน้ำหนักความสำคัญต่อการสร้างเวกเตอร์ความหมายสูงที่สุด ทำให้เวกเตอร์ที่ได้จากโมเดล SPECTER2 ยังคงสามารถจับความหมายของบทความได้อย่างถูกต้องและแม่นยำสูง


3.3 การสร้างเวกเตอร์ความหมายและการทำ L2 Normalization

การสร้าง Document Embeddings ด้วยโมเดล SPECTER2 ร่วมกับ Proximity Adapter จะส่งออกเวกเตอร์แบบหนาแน่น (Dense Feature Vector) ที่มีขนาดมิติเท่ากับ 768 มิติ ($d = 768$) สำหรับบทความแต่ละเรื่อง ขั้นตอนสำคัญที่จำเป็นต้องทำก่อนนำเวกเตอร์ไปใช้งานใน Machine Learning คือ การปรับขนาดเวกเตอร์ด้วย L2 Normalization โดยใช้คำสั่ง `normalize(embeddings, norm='l2')` จากไลบรารี Scikit-learn:


$$v_{\text{norm}} = v / \|v\|_2 \quad \text{โดยที่} \quad \|v\|_2 = \sqrt{\sum (v_i^2)}$$

ประโยชน์ของการทำ L2 Normalization:

1. ทำให้ขนาดของเวกเตอร์ทุกบทความมีความยาวเท่ากับ 1 หน่วย (Unit Sphere)
2. ช่วยให้การคำนวณ Cosine Similarity ระหว่างบทความสองเรื่องสามารถทำได้รวดเร็วขึ้นผ่านการคูณแบบ Dot Product โดยตรง ($v_A \cdot v_B$)
3. ป้องกันปัญหาความเอนเอียง (Bias) ที่เกิดจากความยาวของเอกสาร และช่วยให้อัลกอริทึมประเภท Distance-based (เช่น K-Means, KNN, SVM) ทำงานได้อย่างมีประสิทธิภาพและเข้าสู่คำตอบได้รวดเร็วยิ่งขึ้น



Feature Vector Extraction Workflow



รูปที่ 6: การกระจายตัวของความยาวโทเค็น และขั้นตอนกระบวนการเตรียม Feature Vector

3.4 แนวทางการนำ Feature Vector ไปประยุกต์ใช้ใน Machine Learning

ชุดข้อมูลและเวกเตอร์คุณลักษณะขนาด (6988, 768) ที่สร้างขึ้นนี้ มีความพร้อมสมบูรณ์สำหรับการนำไปฝึกฝนและทดสอบโมเดล Machine Learning ใน 3 โจทย์หลัก:

1. การจำแนกสาขาวิชาอัตโนมัติ (Subject Classification): นำเวกเตอร์ขนาด 768 มิติ เป็น Feature (\$X\$) และใช้คอลัมน์ Subject ทั้ง 10 สาขา เป็นเป้าหมาย (\$y\$) เพื่อฝึกโมเดลเช่น Logistic Regression, Support Vector Machines (SVM) หรือ Multi-Layer Perceptron (MLP) สำหรับจัดหมวดหมู่งานวิจัยใหม่ๆ โดยอัตโนมัติ
2. การจัดกลุ่มเชิงความหมาย (Semantic Clustering): ประยุกต์ใช้อัลกอริทึม K-Means หรือ HDBSCAN ในการจัดกลุ่มบทความโดยไม่ต้องมีป้ายกำกับ (Unsupervised Learning) เพื่อค้นหากลุ่มงานวิจัยย่อย (Sub-topics) หรือสาขาความรู้ใหม่ที่กำลังรวมตัวกันข้ามศาสตร์
3. ระบบสืบค้นและแนะนำบทความที่คล้ายคลึง (Semantic Search & Recommendation): การใช้เทคนิค Approximate Nearest Neighbors (ANN) ในการค้นหาคำถามที่มีเวกเตอร์ใกล้เคียงกัน ช่วยให้นักวิจัยสามารถค้นพบวรรณกรรมที่เกี่ยวข้องได้แม้จะใช้คำสำคัญที่เขียนไม่ตรงกัน

บทสรุปและข้อเสนอแนะ (Conclusion and Recommendations)

การดำเนินโครงการ EDA ข้อมูลวิชาการ Scopus 10 สาขาวิชาในครั้งนี้ ประสบความสำเร็จตามเป้าหมายและข้อกำหนดของรายวิชาอย่างครบถ้วน กลุ่มผู้จัดทำได้เรียนรู้ขั้นตอนการสืบค้นข้อมูลจริงจากฐานข้อมูลมาตรฐานสากล การแก้ปัญหาคุณภาพข้อมูลผ่านกระบวนการ Data Cleaning ที่มีทั้งการกำจัดบทความซ้ำซ้อนข้ามสาขา การคัดกรองบทความที่ขาดบทความย่อหรือบทความต่างภาษา ตลอดจนการคัดแยกบทความนอกศาสตร์คอมพิวเตอร์ ซึ่งช่วยเพิ่มคุณภาพและความน่าเชื่อถือให้แก่ชุดข้อมูลสะอาดจำนวน 6,988 รายการ

ในด้านการแสดงผลด้วยภาพ แดชบอร์ดทั้ง 5 รูปแบบสามารถสะท้อนพลวัตของงานวิจัยได้อย่างลึกซึ้ง โดยชี้ให้เห็นอย่างชัดเจนว่าปัญญาประดิษฐ์ และการเรียนรู้เชิงลึกกำลังเป็นแกนร่วมในการขับเคลื่อนทุกสาขาวิชาทางคอมพิวเตอร์ ขณะที่สถาปัตยกรรมการเตรียม Feature Vector ด้วย SPECTER2 และการทำ L2 Normalization ได้มอบรากฐานอันแข็งแกร่งสำหรับการนำข้อมูลไปพัฒนาระบบ Machine Learning ในขั้นสูงต่อไป

เอกสารอ้างอิง (References)

- Cohan, A., Feldman, S., Beltagy, I., Downey, D., & Weld, D. S. (2020). SPECTER: Document-level Representation Learning using Citation-informed Transformers. Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics (ACL 2020), 2270-2282.
- Elsevier. (2024). Scopus Content Coverage Guide. Elsevier B.V., Amsterdam, Netherlands.
- Kwon, S., & Surinta, O. (2023). Multi-agent and Intelligent Systems in Computer Science: Trends, Co-occurrence Networks, and Research Evolution. Journal of Computer Information Systems.
- Pedregosa, F., et al. (2011). Scikit-learn: Machine Learning in Python. Journal of Machine Learning Research, 12, 2825-2830.
- Surinta, O. (2024). Keyword Co-occurrence Network and Analytics for Generative AI in Higher Education. GitHub Pages: <https://mrolarik.github.io/keyword-co-occurrence-network/>