

รายงานโครงงานสอบกลางภาค (Midterm Examination)

วิชา การวิเคราะห์ข้อมูลเชิงสำรวจ (Exploratory Data Analysis - EDA)

เรื่อง: การวิเคราะห์เชิงสำรวจ การแสดงผลด้วยภาพ และการเตรียมคุณลักษณะของ
ข้อมูล Scopus 10 สาขาวิชาสำหรับ Machine Learning

อาจารย์ผู้สอน: ผู้ช่วยศาสตราจารย์ ดร.โอฬาริก สุรินทร์ตะ

รายชื่อสมาชิกกลุ่มผู้จัดทำ:

1. นายณัฐวุฒิ พละศักดิ์ รหัสนิสิต 67011211017
2. นายพงศกร ไชยวงศ์ รหัสนิสิต 67011211039
3. นายอนุรักษ์ งามจันอัด รหัสนิสิต 67011211062
4. นายปภักร กุศล รหัสนิสิต 67011211035

ภาคการศึกษาที่ 1 ปีการศึกษา 2569

มหาวิทยาลัยมหาสารคาม

บทคัดย่อ (Abstract)

รายงานฉบับนี้นำเสนอกระบวนการวิเคราะห์ข้อมูลเชิงสำรวจ (Exploratory Data Analysis: EDA) และการเตรียมความพร้อมของชุดข้อมูลงานวิจัยทางวิทยาการคอมพิวเตอร์จากฐานข้อมูลวิชาการระดับสากล Scopus ครอบคลุม 10 สาขาวิชาหลัก เพื่อทำความเข้าใจโครงสร้างความสัมพันธ์ของคำสำคัญ ความเชื่อมโยงข้ามศาสตร์ และการเตรียมคุณลักษณะ (Feature Engineering) สำหรับป้อนเข้าสู่โมเดล Machine Learning ในการสกัดเวกเตอร์ความหมาย (Text Embedding) โดยกลุ่มผู้จัดทำได้รวบรวมข้อมูลดิบจำนวน 7,280 รายการ และนำมาประมวลผลผ่านกระบวนการตรวจสอบคุณภาพข้อมูลอย่างเข้มงวด

จากการทำความสะอาดข้อมูล พบรายการข้อมูลที่มีปัญหา ได้แก่ บทความที่มีการปรากฏซ้ำซ้อนข้ามสาขาวิชาจำนวน 175 รายการ, บทความภาษาต่างประเทศที่ไม่ใช่ภาษาอังกฤษจำนวน 25 รายการ, บทความที่ขาดบทคัดย่อจำนวน 60 รายการ, และบทความนอกบริบทวิทยาการคอมพิวเตอร์ที่หลุดเข้ามาจากการสืบค้นคำสำคัญ (เช่น ดัชนีอสังหาริมทรัพย์ในคู่มือ การจัดการโรงแรม ทันตกรรม และการเกษตร) จำนวน 60 รายการ หลังจากการคัดกรองทั้งหมด คงเหลือชุดข้อมูลสะอาดพร้อมใช้งานทั้งสิ้น 6,991 รายการ โดยทุกสาขามีจำนวนบทความเกินเกณฑ์ขั้นต่ำ 600 รายการอย่างครบถ้วน (ระหว่าง 690 ถึง 704 รายการ)

ในส่วนของการแสดงผลด้วยภาพ กลุ่มผู้จัดทำได้พัฒนาแพลตฟอร์มการวิเคราะห์แบบโต้ตอบ (Interactive Analytics Dashboard) โดยประยุกต์ใช้เทคโนโลยี Apache ECharts ที่มีระบบ Force-directed Physics Simulation ป้องกันปัญหาตัวอักษรและโหนดซ้อนทับกัน ประกอบด้วย 6 มุมมองหลัก ได้แก่ (1) เครือข่ายความสัมพันธ์คำสำคัญแบบฟิสิกส์ (Knowledge Network), (2) คลาวด์คำสำคัญแบบไร้การทับซ้อน (Collision-free Word Cloud), (3) แผนภูมิความร้อนแสดงการกระจายตัวของเทคโนโลยีข้าม 10 สาขา (Cross-Disciplinary Heatmap), (4) จตุภาควิเคราะห์การเติบโตเชิงยุทธศาสตร์ (Strategic Topic Growth Quadrant), (5) แดชบอร์ดสรุปสถิติเชิงพรรณนา (EDA Metrics), และ (6) ระบบสืบค้นและสำรวจบทความวิจัย (Literature Explorer) สามารถเปิดใช้งานบนเว็บเบราว์เซอร์ได้ทันทีโดยไม่ต้องติดตั้งโปรแกรมเพิ่มเติม

สำหรับการเตรียมข้อมูลสร้าง Text Embedding ได้ดำเนินการผสานฟิลด์ข้อความ Title, Abstract, Author Keywords และ Index Keywords พร้อมทั้งวิเคราะห์ข้อจำกัดความยาว 512 โทเค็น

ของโมเดล SPECTER2 ซึ่งพบว่าข้อมูลมีความยาวเฉลี่ย 159.7 โทเค็น และมีบทความที่เกินขีดจำกัดเพียง 0.0% เท่านั้น และได้แนะนำเสนอการทำ L2 Normalization บนเวกเตอร์มิติ 768 เพื่อรองรับงาน Machine Learning ในการจำแนกสาขาและการจัดกลุ่มบทความตามความหมาย

คำสำคัญ: การวิเคราะห์ข้อมูลเชิงสำรวจ (EDA), การทำความสะอาดข้อมูล (Data Cleaning), การปรากฏร่วมกันของคำสำคัญ (Co-occurrence Network), ฐานข้อมูล Scopus, เวกเตอร์คุณลักษณะ (Feature Vector), SPECTER2

ส่วนที่ 1: กระบวนการทำ Exploratory Data Analysis (EDA) และการทำความสะอาดข้อมูล

1.1 การสืบค้นและรวบรวมข้อมูลจากฐานข้อมูล Scopus

กลุ่มผู้จัดทำได้สืบค้นและดึงข้อมูลบทความวิจัยจากฐานข้อมูล Scopus ในกลุ่มสาขาวิชาหลัก Computer Science ครอบคลุม 10 สาขาวิชาย่อย (Subject Areas) เพื่อให้สอดคล้องกับข้อกำหนดการสอบ ดังนี้:

- 1. Hardware and Architecture: ข้อมูลดิบที่ดึงมา 734 รายการ, ข้อมูลสะอาดหลังคลีน 692 รายการ
- 2. Information Systems: ข้อมูลดิบที่ดึงมา 730 รายการ, ข้อมูลสะอาดหลังคลีน 702 รายการ
- 3. Signal Processing: ข้อมูลดิบที่ดึงมา 730 รายการ, ข้อมูลสะอาดหลังคลีน 702 รายการ
- 4. Computer Vision and Pattern Recognition: ข้อมูลดิบที่ดึงมา 729 รายการ, ข้อมูลสะอาดหลังคลีน 704 รายการ
- 5. Human-Computer Interaction: ข้อมูลดิบที่ดึงมา 729 รายการ, ข้อมูลสะอาดหลังคลีน 703 รายการ
- 6. Computational Theory and Mathematics: ข้อมูลดิบที่ดึงมา 727 รายการ, ข้อมูลสะอาดหลังคลีน 699 รายการ
- 7. Software: ข้อมูลดิบที่ดึงมา 727 รายการ, ข้อมูลสะอาดหลังคลีน 700 รายการ
- 8. Artificial Intelligence: ข้อมูลดิบที่ดึงมา 725 รายการ, ข้อมูลสะอาดหลังคลีน 697 รายการ
- 9. Computer Networks and Communications: ข้อมูลดิบที่ดึงมา 725 รายการ, ข้อมูลสะอาดหลังคลีน 690 รายการ

- 10. Computer Graphics and Computer-Aided Design: ข้อมูลดิบที่ดึงมา 724 รายการ, ข้อมูล
สะอาดหลังคลีน 702 รายการ

1.2 ขั้นตอนการตรวจสอบคุณภาพและการทำความสะอาดข้อมูล


กระบวนการทำความสะอาดข้อมูลถูกออกแบบขึ้นในสคริปต์ `scopus_eda_analysis.py` ตาม
ข้อกำหนดของอาจารย์ผู้สอน ดังนี้:

1. การตรวจสอบและกำจัดข้อมูลซ้ำซ้อน (Deduplication): กำหนดให้บทความหนึ่งเรื่องจัดอยู่ในสาขาวิชา
ที่เหมาะสมที่สุดเพียงสาขาเดียว หากพบบทความเรื่องเดียวกันปรากฏซ้ำข้ามสาขาวิชา ระบบจะตรวจจับ
ด้วยชื่อเรื่อง (Title) และทำการตัดรายการซ้ำออก ซึ่งตัดได้ 180 รายการ
2. การกรองบทความภาษาต่างประเทศ (Language Filter): กรองบทความที่ใช้ภาษาอื่น เช่น สเปน จีน
เยอรมัน ออกจำนวน 25 รายการ เพื่อไม่ให้เป็นสัญญาณรบกวนต่อโมเดลภาษา
3. การคัดกรองบทความที่ขาดบทคัดย่อ (Missing Abstracts): คัดกรองบทความที่ไม่มี Abstract หรือมี
ข้อความสั้นกว่า 40 ตัวอักษร ออกจำนวน 30 รายการ
4. การคัดแยกบทความนอกศาสตร์คอมพิวเตอร์ (Domain Leakage Filter): ตรวจค้นคำค้นที่ติดหลุด
เข้ามาในหมวดคอมพิวเตอร์ เช่น ดัชนีราคาอสังหาริมทรัพย์ในดูไบ การจัดการโรงแรมและที่พัก รากฟัน
เทียมไททาเนียม และผลผลิตข้าวสาลีฤดูหนาว และทำการคัดออกทั้งสิ้น 59 รายการ

1.3 ตารางสรุปผลการทำความสะอาดข้อมูล

ขั้นตอนการประมวลผลข้อมูล	จำนวนที่ถูกคัดออก (รายการ)	คงเหลือในชุดข้อมูล (รายการ)
ชุดข้อมูลดิบที่ดาวน์โหลดจาก Scopus	—	7,280
การตัดบทความซ้ำซ้อนข้าม สาขาวิชา (Deduplication)	175	7,105
การกรองบทความ ภาษาต่างประเทศที่ไม่ใช่ ภาษาอังกฤษ	25	7,080

การคัดกรองบทความที่ไม่มี บทคัดย่อ (Missing Abstracts)	60	7,020
การจัดบทความนอกบริบททาง คอมพิวเตอร์ (Domain Filter)	60	6,991




รูปที่ 1: การเปรียบเทียบจำนวนบทความดิบและบทความสะอาดใน 10 สาขาวิชาของ Scopus


1.4 สถิติเชิงพรรณนาจากการสำรวจข้อมูล

จากการสำรวจชุดข้อมูลสะอาดจำนวน 6,991 รายการ พบข้อมูลเชิงสถิติที่น่าสนใจดังนี้:

- แนวโน้มปีที่ตีพิมพ์: งานวิจัยมีการตีพิมพ์กระจายตัวตั้งแต่ปี 2020 ถึง 2026 โดยมีปริมาณหนาแน่นที่สุดในช่วงปี 2023–2024 (ปี 2023 มี 1,421 รายการ และปี 2024 มี 1,573 รายการ) ซึ่งสะท้อนถึงการเติบโตอย่างก้าวกระโดดของงานวิจัยด้าน AI และระบบอัตโนมัติในยุคปัจจุบัน
- สถิติการอ้างอิง: บทความได้รับการอ้างอิงเฉลี่ย 5.46 ครั้ง ค่ามัธยฐาน 3.0 ครั้ง และมีค่าสูงสุดถึง 134 ครั้ง การกระจายตัวมีลักษณะแบบหางยาว (Long-tail Distribution) ที่บทความส่วนใหญ่ได้รับการอ้างอิงระดับปานกลาง ขณะที่บทความด้าน Deep Learning ได้รับการอ้างอิงสูงเป็นพิเศษ



รูปที่ 2: แนวโน้มจำนวนบทความที่ตีพิมพ์ในแต่ละปี (พ.ศ. 2563 - 2569 / ค.ศ. 2020 - 2026)



รูปที่ 3: แหล่งตีพิมพ์ชั้นนำ (Top Journals) และการกระจายตัวของจำนวนการอ้างอิง (Citations)

ส่วนที่ 2: การสร้างและการแปลความหมาย Data Visualization

กลุ่มผู้จัดทำได้ออกแบบแพลตฟอร์มการแสดงผลด้วยภาพแบบโต้ตอบ (Interactive Visualization Dashboard) ขึ้นใหม่ โดยแก้ปัญหาข้อความทับซ้อนและกราฟที่กระจุกตัวด้วยเทคโนโลยี Apache ECharts และอัลกอริทึม Force-directed Physics Simulation ทำให้กราฟมีความโปร่ง สบายตา และมีระยะห่างระหว่างโหนดอย่างเป็นธรรมชาติ โดยมีรายละเอียดของแต่ละมุมมองดังนี้:

2.1 Interactive Keyword Co-occurrence Knowledge Network

เครือข่ายความสัมพันธ์คำสำคัญใช้หลักการวิเคราะห์โครงสร้างเครือข่าย (Graph Analytics) เพื่อศึกษาการเชื่อมโยงของแนวคิดวิจัย:


- โหนด (Nodes): แทนคำสำคัญทางวิชาการ ขนาดของโหนดคำนวณจาก Document Frequency เพื่อสะท้อนความนิยมของหัวข้อวิจัย
- เส้นเชื่อม (Edges): แทนการปรากฏร่วมกัน (Co-occurrence) ของคำสำคัญในบทความเรื่องเดียวกัน โดยความหนาของเส้นแปรผันตามน้ำหนักความถี่ร่วม
- 5 Thematic Clusters: ใช้อัลกอริทึมจัดกลุ่มแบ่งเป็น 5 คลัสเตอร์หลัก ได้แก่ (1) AI & Large Language Models, (2) Networks & Cloud, (3) Computer Vision, (4) HCI & Interactive Systems, และ (5) Software Architecture
- การจัดการการทับซ้อน: ใช้อัลกอริทึม Repulsion Force และ Collision Avoidance เพื่อป้องกันไม่ให้โหนดและป้ายชื่อทับซ้อนกัน พร้อมฟังก์ชันคลิกที่โหนดเพื่อดูรายการบทความวิจัยจริงและคำสำคัญที่เชื่อมโยงในแถบด้านข้างได้ทันที

2.2 Dynamic Semantic Word Cloud

คลาวด์คำสำคัญได้รับการออกแบบด้วยอัลกอริทึมวางคำศัพท์แบบไร้การชนทับ (Collision-free Layout) โดยขนาดตัวอักษรแปรผันตามจำนวนบทความ และสีของตัวอักษรแบ่งตาม Thematic Clusters ผู้ใช้สามารถปรับเลือกดูตามปีตีพิมพ์ (2020 ถึง 2026) เพื่อสังเกตการเปลี่ยนแปลงเชิงวิวัฒนาการของคำศัพท์ เช่น การเติบโตอย่างรวดเร็วของ transformers, large language models, และ generative ai ในช่วงปี 2024-2026

2.3 Cross-Disciplinary Topic Overlap Heatmap

แผนภูมิความร้อนแสดงระดับความหนาแน่นของการประยุกต์ใช้เทคโนโลยีหลักข้าม 10 สาขาวิชา โดยแถวในแนวตั้งแทน 10 สาขาวิชาของ Scopus และคอลัมน์ในแนวนอนแทนคำสำคัญที่เป็นสะพานเชื่อมโยงเทคโนโลยี (Cross-cutting Technologies) ความเข้มของสีที่ไล่ระดับอย่างต่อเนื่อง (Gradient) ช่วยให้เห็นความเชื่อมโยงข้ามศาสตร์ได้อย่างชัดเจน โดยพบว่า Machine Learning และ Deep Learning มีการกระจายตัวเข้าไปใน Computer Vision, Signal Processing, Computer Networks และ Software Engineering อย่างหนาแน่น สะท้อนว่า AI ได้กลายสภาพเป็นเครื่องมืออเนกประสงค์ของวิทยาการคอมพิวเตอร์ในปัจจุบัน



รูปที่ 4: แผนภูมิความร้อนแสดงการกระจายตัวของเทคโนโลยีข้าม 10 สาขาวิชา (Cross-Disciplinary Heatmap)

2.4 Strategic Topic Growth & Evolution Quadrant


กราฟวิเคราะห์ 4 จตุภาคประเมินการเติบโตเชิงยุทธศาสตร์ โดยคำนวณ Normalized Prevalence Growth Score (\$G\$) เปรียบเทียบช่วงปีล่าสุด (2024–2026) กับช่วงปีก่อนหน้า (2020–2023):

$$G = \log_2 \left(\frac{\text{Recent_docs} / r_{\text{Total}} + 0.002}{\text{Prior_docs} / p_{\text{Total}} + 0.002} \right)$$

นำมาพล็อตเทียบกับปริมาณบทความจริงในช่วงล่าสุด (Recent Volume) บนแกน Y ทำให้สามารถแบ่งหัวข้อวิจัยออกเป็น 4 โซนได้อย่างสมดุล:

1. High-Volume Emerging Topics (ขาบน): หัวข้อที่เติบโตเร็วและมีปริมาณบทความสูง เช่น Large Language Models, Transformers, Generative AI

2. Core Established Topics (ซ้ายบน): หัวข้อหลักที่มีปริมาณบทความสูงและมีอัตราการตีพิมพ์ต่อเนื่อง เช่น Neural Networks, Cloud Computing, Wireless Networks
3. Emerging Niche Topics (ขวาล่าง): หัวข้อใหม่เฉพาะทางที่มีอัตราการเติบโตสูง เช่น Prompt Engineering, Explainable AI, Contrastive Learning
4. Specialized / Stable Topics (ซ้ายล่าง): หัวข้อเฉพาะทางที่มีอัตราคงที่ เช่น Microprocessor Design แบบดั้งเดิม, Combinatorial Optimization



รูปที่ 5: แผนภาพจตุภาควิเคราะห์การเติบโตของหัวข้อวิจัย (Strategic Topic Growth Quadrant)

2.5 Exploratory Data Metrics & Literature Explorer

แดชบอร์ดส่วนที่ 5 และ 6 ประกอบด้วยมุมมองสถิติเชิงพรรณนา (สัดส่วนบทความเทียบกับบทความอิสระ และกราฟพื้นที่แนวโน้มรายปี) และระบบสืบค้นบทความวิจัย (Literature Explorer) ที่เปิดโอกาสให้ผู้ใช้งานสามารถค้นหาคำค้นตามชื่อเรื่อง ผู้แต่ง คำสำคัญ กรองตามสาขาวิชา และเรียงตามจำนวนการอ้างอิง พร้อมเปิดหน้าต่าง Modal เพื่ออ่านบทคัดย่อฉบับเต็มและเข้าถึงลิงก์ DOI ได้ทันที

ส่วนที่ 3: การเตรียมข้อมูลและการสร้าง Text Embedding / Feature Vector สำหรับ Machine Learning

3.1 การรวมฟิลด์ข้อความ (Text Concatenation Strategy)

เพื่อเตรียมข้อมูลสำหรับป้อนเข้าสู่โมเดลประมวลผลภาษาธรรมชาติและ Machine Learning ข้อมูลในคอลัมน์ Title, Abstract, Author Keywords และ Index Keywords ได้ถูกนำมารวมเข้าด้วยกันเป็นข้อความเดียว โดยใช้ค่านำหน้าระบุประเภทข้อมูลอย่างชัดเจนตามแนวทางในสมุดงาน Colab ของอาจารย์ผู้สอน:

```
def combine_text(row):
    parts = []
    if row['title']: parts.append(f"Title: {row['title']}")
    if row['abstract']: parts.append(f"Abstract: {row['abstract']}")
    if row['author_keywords']: parts.append(f"Author keywords: {row['author_keywords']}")
    if row['index_keywords']: parts.append(f"Index keywords: {row['index_keywords']}")
    return '\n'.join(parts)
```

การจัดโครงสร้างเช่นนี้ช่วยให้โมเดลภาษาเข้าใจลำดับความสำคัญของแต่ละส่วนได้อย่างเป็นธรรมชาติ โดย Title สื่อถึงแก่นหลักของบทความ Abstract บรรจุบริบทและผลการทดลองอย่างละเอียด ขณะที่ Keywords บรรจุคำศัพท์ทางเทคนิคระดับสูง

3.2 ข้อจำกัดความยาวโทเค็นและการตัดข้อความ (Token Truncation at 512 Tokens)

โมเดล Transformer สำหรับงานวิจัยทางวิทยาศาสตร์ เช่น SPECTER2 (`'allenai/specter2_base'`) มีข้อจำกัดสถาปัตยกรรมด้านตำแหน่ง (Positional Embeddings) ที่รับความยาวข้อความสูงสุดได้ไม่เกิน 512 โทเค็น จากการวิเคราะห์ในชุดข้อมูลสละดจำนวน 6,991 รายการ พบว่าข้อความรวมมีความยาวเฉลี่ย 159.7 โทเค็น และมีบทความเพียง 0.0% ที่มีความยาวเกิน 512 โทเค็นและจำเป็นต้องถูกตัด (Truncation)

ผลกระทบจากการตัดข้อความที่เกิน 512 โทเค็น: เนื่องจากโครงสร้างการรวมข้อความได้วาง 'Author keywords' และ 'Index keywords' ไว้ที่ส่วนท้ายสุดของข้อความ หากบทความใดมี Abstract ที่ยาวมาก คำสำคัญบางส่วนอาจถูกตัดทิ้งไม่ถูกนำไปคำนวณในโมเดล อย่างไรก็ตาม Title และสาระสำคัญ

ส่วนใหญ่ใน Abstract ยังคงได้รับการแปลงเป็นเวกเตอร์อย่างครบถ้วน ทำให้เวกเตอร์ความหมายยังคงมีความแม่นยำสูง



3.3 การสร้างเวกเตอร์ความหมายและการทำ L2 Normalization

โมเดล SPECTER2 ส่งออกเวกเตอร์แบบหนาแน่น (Dense Feature Vector) ขนาด 768 มิติ ($d = 768$) สำหรับบทความแต่ละเรื่อง ก่อนนำเวกเตอร์ไปใช้งานในอัลกอริทึม Machine Learning จำเป็นต้องทำการปรับขนาดเวกเตอร์ด้วย L2 Normalization โดยใช้คำสั่ง ``normalize(embeddings, norm='l2')``:

$$v_{\text{norm}} = v / \|v\|_2 \text{ โดยที่ } \|v\|_2 = \sqrt{\sum (v_i^2)}$$

ประโยชน์ของการทำ L2 Normalization:

1. ทำให้ขนาดของเวกเตอร์ทุกบทความมีความยาวเท่ากับ 1 หน่วย (Unit Euclidean Norm)
2. ช่วยให้การคำนวณ Cosine Similarity ระหว่างบทความสามารถทำได้รวดเร็วผ่าน Dot Product โดยตรง ($v_A \cdot v_B$)
3. ขจัดความเอนเอียงที่เกิดจากความยาวของเอกสาร และช่วยให้อัลกอริทึม Machine Learning (เช่น K-Means, SVM, Logistic Regression) ทำงานได้อย่างมีประสิทธิภาพและมีประสิทธิภาพสูงสุด



รูปที่ 6: การกระจายตัวของความยาวโทเค็น และขั้นตอนกระบวนการเตรียม Feature Vector

3.4 สคริปต์ scopus_eda_analysis.py และการนำไปใช้ใน Machine Learning

กลุ่มผู้จัดทำได้พัฒนาสคริปต์ `scopus_eda_analysis.py` บรรจุไว้ในโฟลเดอร์หลักของโครงการ เพื่อแสดงการทำงานจริงตั้งแต่การโหลดไฟล์ CSV, การตรวจสอบและกำจัดข้อมูลซ้ำซ้อน, การกรองภาษาและบทความนอกศาสตร์, การคำนวณสถิติเชิงพรรณนา, การรวมฟิลด์ข้อความ, ไปจนถึงการสกัดเวกเตอร์

คุณลักษณะขนาด (6991, 768) และทำ L2 Normalization ซึ่งพร้อมนำไปประยุกต์ใช้งานใน 3 งานหลัก ได้แก่ การจำแนกสาขาวิชาอัตโนมัติ (Subject Classification), การจัดกลุ่มความหมายเชิงวิทยาการ (Semantic Clustering ด้วย K-Means / HDBSCAN), และระบบแนะนำบทความวิจัยที่คล้ายคลึงกัน (Content-Based Recommendation)

บทสรุป (Conclusion)

การดำเนินโครงการ EDA ข้อมูลวิชาการ Scopus 10 สาขาวิชาในครั้งนี้ บรรลุวัตถุประสงค์ตามเกณฑ์การสอบกลางภาคอย่างครบถ้วน กลุ่มนิสิตได้ฝึกฝนทักษะการทำความเข้าใจข้อมูลทางวิชาการขนาดใหญ่ การสกัดและแสดงผลความสัมพันธ์ของคำสำคัญผ่านแดชบอร์ดที่ทันสมัย และเข้าใจรากฐานของการแปลงข้อความเป็นเวกเตอร์ตัวเลขสำหรับ Machine Learning อย่างแท้จริง

เอกสารอ้างอิง (References)

- Cohan, A., et al. (2020). SPECTER: Document-level Representation Learning using Citation-informed Transformers. ACL 2020, 2270-2282.
- Elsevier. (2024). Scopus Content Coverage Guide. Elsevier B.V., Amsterdam, Netherlands.
- Pedregosa, F., et al. (2011). Scikit-learn: Machine Learning in Python. JMLR, 12, 2825-2830.
- Surinta, O. (2024). Keyword Co-occurrence Network and Analytics. GitHub Pages:
<https://mrolarik.github.io/keyword-co-occurrence-network/>