

Scopus EDA & Feature Vector Pipeline

การวิเคราะห์ข้อมูลเชิงสำรวจและการเตรียมคุณลักษณะ Scopus 10 สาขาวิชาสำหรับ Machine Learning

วิชา: การวิเคราะห์ข้อมูลเชิงสำรวจ (Exploratory Data Analysis - EDA) | สอบ Midterm งานกลุ่ม

อาจารย์ผู้สอน: ผู้ช่วยศาสตราจารย์ ดร.โอฬาริก สุรินทร์

กลุ่มผู้จัดทำ: นายณัฐวุฒิ พลศักดิ์ (67011211017) · นายพงศกร ไชยวงศ์ (67011211039) · นายอนุรักษ์ งามจันอัด (67011211062) · นายปภักร กุศล (67011211035)

ที่มาและความสำคัญ: จากข้อมูลวิชาการสู่ **Machine Learning**

1. Scopus Ingestion

- สืบค้นและรวบรวมข้อมูล 10 Subject ในหมวด Computer Science
- เป้าหมายอย่างน้อยสาขาละ 600 รายการ รวมกว่า 7,200 รายการดิบ
- ครอบคลุมข้อมูลทั้ง Citation, Bibliographical, Abstract, Keywords

2. Rigorous EDA & Cleaning


- กำจัดบทความซ้ำซ้อนข้ามสาขา (1 บทความต่อ 1 สาขา เท่านั้น)
- กรองบทความภาษาต่างประเทศ และบทความที่ไม่มีบทคัดย่อ
- คัดแยกบทความนอกศาสตร์ (เช่น อสังหาริมทรัพย์, ท่องเที่ยว) ที่หลุดเข้ามา

3. ML Feature Vector

- ประกอบข้อความ Title + Abstract + Keywords
- วิเคราะห์ข้อจำกัดความยาว 512 โทเค็นของโมเดล SPECTER2
- สกัดเวกเตอร์ 768 มิติ และทำ L2 Normalization พร้อมสำหรับการเทรน

DATASET OVERVIEW

การรวบรวมข้อมูล Scopus 10 สาขาวิชา (7,280 รายการดิบ)



เกณฑ์การจัดเก็บข้อมูล (Scopus)

- 10 Subject Areas: AI, Computational Theory, Graphics/CAD, Networks, Computer Vision, Hardware, HCI, Information Systems, Signal Processing, Software
- ปริมาณข้อมูลดิบ: คัดมาเฉลี่ยสาขาละ 719–739 รายการ รวม 7,280 รายการ
- เกณฑ์ขั้นต่ำ: กำหนดให้อย่างน้อยสาขาละ 600 รายการ
- ผลหลังทำความสะอาด: ทุกสาขามีบทความสะอาด 694–704 รายการ (ผ่านเกณฑ์ขั้นต่ำ 100%)

กระบวนการตรวจสอบและทำความสะอาดข้อมูล (ขจัดสิ่งเจือปน 292 รายการ)

1. Remove Duplicates

ตัดข้อมูลซ้ำซ้อน

คัดออก: 178 รายการ

บทความปรากฏซ้ำข้ามสาขา เช่น พบบทความเดียวกันใน AI และ Software กำหนดให้อยู่สาขาเดียวเท่านั้น

2. Language Filter

กรองบทความต่างภาษา

คัดออก: 25 รายการ

คัดกรองบทความภาษาอื่นที่ไม่ใช่ภาษาอังกฤษ (จีน, สเปน, ฝรั่งเศส, เยอรมัน) เพื่อไม่ให้รบกวน NLP Model

3. Missing Abstracts

คัดกรองบทความที่ขาดย่อหน้า

คัดออก: 30 รายการ

ตัดบทความที่ไม่มีบทคัดย่อ หรือบทคัดย่อสั้นกว่า 40 ตัวอักษร เช่น บทความประเภท Editorial หรือ Correction



4. Domain Leakage

ขจัดบทความนอกศาสตร์

คัดออก: 59 รายการ

กรองบทความที่ไม่เกี่ยวข้องกับคอมฯ เช่น คณิตศาสตร์, อสังหาริมทรัพย์, การท่องเที่ยว, รากฟันเทียม และผลิตภัณฑ์ชีวสาลี

สถิติเชิงพรรณนา: แนวโน้มปีที่ตีพิมพ์และการกระจายตัวของ Citation



Keyword Co-occurrence Network: โครงสร้างความสัมพันธ์คำสำคัญ


หลักการและความสัมพันธ์กับข้อมูล

- โหนด (Nodes): แทนคำสำคัญ โดยรัศมีคำนวณจาก Document Frequency (ความถี่ที่พบในบทความ)
- เส้นเชื่อม (Edges): แทนการปรากฏร่วมกัน (Co-occurrence) ความหนาแปรผันตามน้ำหนักความถี่ร่วม
- 5 Thematic Clusters: จัดกลุ่มชุมชนคำศัพท์ด้วย Modularity: AI, Networks, Vision, HCI, และ Software
- การสลับโหมดสี: สลับดู Cluster หรือ Average Publication Year เพื่อดูวิวัฒนาการตามช่วงเวลา
- Interactivity: ชุม เลื่อน กรอง Document Threshold และคลิกโหนดเพื่อดูรายการบทความจริง

5 กลุ่มสาระงานวิจัยที่ค้นพบ (Thematic Clusters)

- Cluster 1 (น้ำเงิน): AI, Large Models & Deep Learning (transformers, prompt engineering, llms)
- Cluster 2 (เขียว): Networks, Cloud & Cybersecurity (iot, 5g, sdn, edge computing)
- Cluster 3 (ม่วง): Computer Vision & Pattern Recognition (object detection, yolo, segmentation)
- Cluster 4 (ส้ม): HCI, UI/UX & Interactive Systems (virtual reality, user experience, eye tracking)
- Cluster 5 (ชมพู): Software Engineering & Architecture (devops, microservices, testing, refactoring)


Word Cloud ตามช่วงปี และ Cross-Subject Topic Overlap Heatmap



ข้อค้นพบจากการวิเคราะห์ข้ามสาขา

- **Interactive Word Cloud:** สามารถฟิลเตอร์ดูรายปี (2020 ถึง 2026) พบว่าคำว่า 'transformers' และ 'large language models' ขยายตัวเร็วที่สุดในกลุ่มคำสำคัญ
- **AI as General-Purpose Tech:** จากแผนภูมิความร้อนด้านซ้าย คำว่า 'deep learning' และ 'machine learning' มีการปรากฏข้ามไปใน Computer Vision, Signal Processing, และ Software อย่างหนาแน่น
- **Cross-disciplinary Flow:** แสดงให้เห็นว่าศาสตร์ทางคอมพิวเตอร์ในปัจจุบันเกิดการบูรณาการเครื่องมือ AI เข้าสู่ทุกสาขาวิชาอย่างชัดเจน

Strategic Topic Growth Quadrant: การคาดการณ์แนวโน้มงานวิจัย



การแบ่ง 4 จตุภาคเชิงยุทธศาสตร์

- สูตรการเติบโตเชิงสัมพัทธ์: $\log_2(\text{Recent}_{2024_2026} / \text{Prior}_{2020_2023})$
- High-Volume Emerging (ขวาบน): Large Language Models, Transformers, Foundation Models (โตเร็ว บทความสูง)
- Established Topics (ซ้ายบน): Cloud Computing, Wireless Sensor Networks (งานวิจัยหลัก ทรงตัว)
- Emerging Niche (ขวาล่าง): Prompt Engineering, Contrastive Learning, Explainable AI (หัวข้อใหม่ โตแรง)
- Declining / Stable Niche (ซ้ายล่าง): Shader Programming, Microprocessors (ดั้งเดิม)

การรวมฟิลด์ข้อความ (Text Concatenation Strategy)

ฟังก์ชันรวมข้อความตาม Colab ของอาจารย์


```
def combine_text(row):
    text_parts = []
    if row['title']:
        text_parts.append(f"Title: {row['title']}")
    if row['abstract']:
        text_parts.append(f"Abstract: {row['abstract']}")
    if row['author_keywords']:
        text_parts.append(f"Author keywords: {row['author_keywords']}")
    if row['index_keywords']:
        text_parts.append(f"Index keywords: {row['index_keywords']}")
    return '\n'.join(text_parts)
```

เหตุผลและความสำคัญของโครงสร้างข้อความ

- บุคลากร 4 องค์ประกอบสำคัญ: ผสาน Title, Abstract, Author Keywords และ Index Keywords เป็นประโยคเดียวที่สมบูรณ์
- Section Identifiers: ใส่แท็ก 'Title:', 'Abstract:', 'Keywords:' ชัดเจน เพื่อให้โมเดลแยกแยะบทบาทของแต่ละส่วนได้
- Semantic Enrichment: Keywords ช่วยเสริมบริบทคำศัพท์เฉพาะทาง ขณะที่ Abstract ให้รายละเอียดบริบทการทดลอง
- Consistency: รับประกันว่าข้อมูลนำเข้าของทุกบทความมีรูปแบบสม่ำเสมอสำหรับการ Tokenize

MODEL ARCHITECTURE

การจัดการข้อจำกัด 512 โทเค็นและโมเดล SPECTER2



Feature Vector Extraction Workflow

Title + Abstract + Author Keywords + Index Keywords

Special Token Insertion: [SEP] Concatenation
Max Token Truncation (512 tokens)

SPECTER2 Base Model + Proximity Adapter
Dense Semantic Projection ($d = 768$)

L2 Normalization (Unit Length Euclidean Norm)
Output Feature Vector: (N, 768)

ข้อจำกัด 512 Tokens & SPECTER2

- SPECTER2 Base + Proximity Adapter: โมเดลที่เทรนด้วย Citation Graph เหมาะอย่างยิ่งสำหรับงานจับคู่เอกสารทางวิทยาศาสตร์
- Max Length 512 Tokens: โมเดลรับได้สูงสุด 512 โทเค็น ข้อมูลมีความยาวเฉลี่ย 318 โทเค็น มีบทความที่เกินเพียงส่วนน้อย
- ผลกระทบจากการตัดข้อความ: Keywords อยู่ท้ายข้อความจึงอาจถูกตัดในบทความที่ Abstract ยาวมาก แต่ Title และเนื้อหาหลักยังถูกแปลงเป็นเวกเตอร์ได้อย่างครบถ้วน
- Vector Dimension: ส่งออก Dense Representation ขนาด 768 มิติ

L2 Normalization และการนำไปใช้ใน Machine Learning

1. L2 Normalization

- ปรับขนาดเวกเตอร์ด้วยคำสั่ง:
`normalize(embeddings, norm='l2')`
- เวกเตอร์ทุกตัวมีความยาวเท่ากับ 1 (Unit Euclidean Length)
- Cosine Similarity คำนวณได้ทันทีด้วย Dot Product (เร็วกว่าเดิมมาก)

2. Subject Classification

- การจำแนกสาขาวิชาอัตโนมัติ (Supervised Learning)
- Features (X): เวกเตอร์ขนาด 768 มิติ
- Target (y): 10 สาขาวิชาใน Scopus
- โมเดลที่เหมาะสม: Logistic Regression, SVM, หรือ Multi-Layer Perceptron (MLP)

3. Clustering & Search

- Semantic Clustering (K-Means, HDBSCAN) เพื่อค้นพบกลุ่มวิจัยใหม่แบบไม่ต้องมี Label
- Semantic Recommendation ด้วย Approximate Nearest Neighbors (ANN)
- แนะนำบทความที่เนื้อหาคล้ายกัน แม้ใช้สปีชีแวลด์คนละคำ

KEY DELIVERABLES

สรุปผลสัมฤทธิ์โครงการและสิ่งที่ส่งมอบ

สรุปภาพรวมผลการดำเนินงาน

- ✓ ชุดข้อมูลวิชาการ Scopus 10 สาขา: รวบรวมข้อมูลดิบ 7,280 รายการ ผ่านการคลีนเหลือ 6,988 รายการ (ทุกสาขาเกิน 600 รายการอย่างครบถ้วน)
- ✓ การทำความสะอาดข้อมูลตามโจทย์: กำจัดบทความซ้ำข้ามสาขา 178 รายการ, ภาษาคำต่างประเทศ 25 รายการ, ขาด Abstract 30 รายการ, และบทความนอกศาสตร์ 59 รายการ
- ✓ เว็บไซต์ Interactive Dashboard 5 มุมมอง: Co-occurrence Network, Word Cloud, Overlap Heatmap, Topic Quadrant, Document Explorer รันบน Browser ได้ทันทีไม่ต้องลงโปรแกรมเพิ่ม
- ✓ Feature Vector & ML Readiness: สร้างเวกเตอร์ขนาด (6988, 768) ด้วยสถาปัตยกรรม SPECTER2 พร้อม L2 Normalization
- ✓ เอกสารรายงานและสไลด์สมบูรณ์: จัดทำ Report ครบ 3 ส่วนในรูปแบบ DOCX (ฟอนต์ TH Sarabun New) และ PDF พร้อมสไลด์ PPTX และ PDF

Thank You for Your Attention

ช่วงถาม-ตอบ (Q & A) และช่องทางเข้าชมผลงานออนไลน์

- Online Interactive Dashboard (GitHub Pages): เข้าถึงและทดลองใช้งานกราฟโต้ตอบแบบเรียลไทม์ได้ทันที
- สมาชิกกลุ่ม: ฉัฐวดี 67011211017 · พงศกร 67011211039 · อนุรักษ์ 67011211062 · ปกักร 67011211035
- อาจารย์ผู้สอน: ผศ.ดร.โอฬาริก สุรินตะ (วิชา EDA)