

Scopus EDA & Feature Vector Pipeline

การวิเคราะห์ข้อมูลเชิงสำรวจและการเตรียมคุณลักษณะ Scopus 10 สาขาวิชาสำหรับ Machine Learning

วิชา: การวิเคราะห์ข้อมูลเชิงสำรวจ (Exploratory Data Analysis - EDA) | สอบ Midterm งานกลุ่ม

อาจารย์ผู้สอน: ผู้ช่วยศาสตราจารย์ ดร.โอฬาริก สุรินตะ

กลุ่มผู้จัดทำ: นายณัฐวุฒิ พละศักดิ์ (67011211017) · นายพงศกร ไชยวงศ์ (67011211039) · นายอนุรักษ์ งามจันอัด (67011211062) · นายปภักร กุศล (67011211035)

ที่มาและความสำคัญ: จากข้อมูลวิชาการสู่ **Machine Learning**

1. Scopus Ingestion

- สืบค้นและรวบรวมข้อมูล 10 Subject ในหมวด Computer Science
- เป้าหมายอย่างน้อยสาขาละ 600 รายการ รวม 7,280 รายการดิบ
- ครอบคลุมข้อมูลทั้ง Citation, Bibliographical, Abstract, Keywords

2. Rigorous EDA & Cleaning


- ดำเนินการผ่านสคริปต์ `scopus_eda_analysis.py`
- กำจัดบทความซ้ำข้ามสาขา (1 บทความต่อ 1 สาขา เท่านั้น)
- กรองบทความภาษาต่างประเทศ, ขาดบทคัดย่อ และบทความนอกศาสตร์คอมพิวเตอร์

3. ML Feature Vector

- ประกอบข้อความ Title + Abstract + Keywords
- วิเคราะห์ข้อจำกัดความยาว 512 โทเค็นของโมเดล SPECTER2
- สกัดเวกเตอร์ 768 มิติ และทำ L2 Normalization พร้อมสำหรับการเทรน

DATASET OVERVIEW

การรวบรวมข้อมูล Scopus 10 สาขาวิชา (7,280 รายการดิบ)



เกณฑ์การจัดเก็บข้อมูล (Scopus)

- 10 Subject Areas: AI, Computational Theory, Graphics/CAD, Networks, Computer Vision, Hardware, HCI, Information Systems, Signal Processing, Software
- ปริมาณข้อมูลดิบ: คัดมาเฉลี่ยสาขาละ 719–739 รายการ รวม 7,280 รายการ
- เกณฑ์ขั้นต่ำ: กำหนดให้อย่างน้อยสาขาละ 600 รายการ
- ผลหลังทำความสะอาด: ทุกสาขามีบทความสะอาด 690–704 รายการ (ผ่านเกณฑ์ขั้นต่ำ 100%)

DATA CLEANING PIPELINE

กระบวนการตรวจสอบและทำความสะอาดข้อมูล (ขจัดสิ่งเจือปน 289 รายการ)

1. Remove Duplicates

ตัดข้อมูลซ้ำซ้อน

คัดออก: 180 รายการ

บทความปรากฏซ้ำข้ามสาขา เช่น พบบทความเดียวกันใน AI และ Software กำหนดให้อยู่สาขาเดียวเท่านั้น

2. Language Filter

กรองบทความต่างภาษา

คัดออก: 25 รายการ

คัดกรองบทความภาษาอื่นที่ไม่ใช่ภาษาอังกฤษ (จีน, สเปน, ฝรั่งเศส, เยอรมัน) เพื่อไม่ให้รบกวน NLP Model

3. Missing Abstracts

คัดกรองบทความที่ขาดย่อหน้า

คัดออก: 30 รายการ

ตัดบทความที่ไม่มีบทคัดย่อ หรือบทคัดย่อสั้นกว่า 40 ตัวอักษร เช่น บทความประเภท Editorial หรือ Correction



4. Domain Leakage

ขจัดบทความนอกศาสตร์

คัดออก: 59 รายการ

กรองบทความที่ไม่เกี่ยวข้องกับคอมฯ เช่น คณิตศาสตร์, การท่องเที่ยว, รากฟันเทียม และผลผลิตข้าวสาลี

สถิติเชิงพรรณนา: แนวโน้มปีที่ตีพิมพ์และการกระจายตัวของ Citation



ระบบแดชบอร์ด **Apache ECharts** พร้อม **Force-directed Physics**


การแก้ปัญหาการทับซ้อนและความสวยงาม

- **Force-directed Simulation:** ใช้แรงผลักระหว่างโหนด (Repulsion) ป้องกันปัญหาข้อความทับซ้อนกัน
- **Collision-free Word Cloud:** จัดวางคำสำคัญในคลาวด์แบบไม่มีคำทับซ้อน พร้อมฟิลเตอร์รายปี
- **Gradient Heatmap:** แผนภูมิความร้อนไล่ระดับสีต่อเนื่อง เห็นการแพร่กระจายของเทคโนโลยีชัดเจน
- **Dynamic Interactivity:** คลิกโหนดเพื่อเปิดดูบทความจริง และลิงก์ไปยัง Document Explorer ได้ทันที
- **100% Offline & GitHub Pages:** บันทึกไลบรารี ECharts ไว้ในโปรเจกต์ รันได้ทันทีโดยไม่ต้องต่ออินเทอร์เน็ต

6 มุมมองบนเว็บแอปพลิเคชัน (Web Dashboard)

- 1. Knowledge Network: เครือข่ายความสัมพันธ์คำสำคัญแบบฟิสิกส์ 5 กลุ่มสาระ
- 2. Semantic Word Cloud: คลาวด์คำสำคัญไร้การทับซ้อน กรองเลือกรายปี 2020-2026
- 3. Cross-Disciplinary Heatmap: แผนภูมิความร้อนการประยุกต์ใช้เทคโนโลยีข้าม 10 สาขา
- 4. Topic Growth Quadrant: จตุภาควิเคราะห์การเติบโตเชิงยุทธศาสตร์ 4 โซน
- 5. EDA Descriptive Metrics: สถิติเชิงพรรณนา สัดส่วนข้อมูลดิบและแนวโน้มรายปี
- 6. Scopus Literature Explorer: ระบบค้นหาบทความวิจัย บทคัดย่อ และลิงก์ DOI


Cross-Disciplinary Heatmap: การถ่ายทอดเทคโนโลยีข้ามสาขา



ข้อค้นพบจากการวิเคราะห์ข้ามสาขา

- AI As Cross-Cutting Foundation: Machine Learning และ Deep Learning แทรกซึมเข้าไปในแทบทุกสาขา โดยเฉพาะ Computer Vision, Signal Processing, และ Software Engineering
- Infrastructure & Systems: Cloud Computing และ Edge Computing เป็นแกนกลางสำคัญใน Computer Networks และ Information Systems
- Continuous Gradient: แผนภูมิความร้อนแบบใหม่ใช้การไล่ระดับสีที่ต่อเนื่อง ช่วยให้เห็นความเชื่อมโยงของแต่ละเทคโนโลยีได้อย่างเป็นรูปธรรม

Strategic Topic Growth Quadrant: การประเมินทิศทางการวิจัย



การแบ่ง 4 โซนเชิงยุทธศาสตร์

- สูตรการเติบโตเชิงสัมพัทธ์: $\log_2(\text{Recent}_{2024_2026} / \text{Prior}_{2020_2023})$
- High-Volume Emerging (ขวาบน): Large Language Models, Transformers, Generative AI (โตเร็ว ปริมาณสูง)
- Core Established (ซ้ายบน): Neural Networks, Cloud Computing, Wireless Networks (งานวิจัยหลัก ทรงตัว)
- Emerging Niche (ขวาล่าง): Prompt Engineering, Explainable AI, Contrastive Learning (หัวข้อใหม่ โตแรง)
- Specialized / Stable (ซ้ายล่าง): Combinatorial Optimization, Microprocessor Design (ดั้งเดิม)

การรวมฟิลด์ข้อความ (Text Concatenation Strategy)

ฟังก์ชันรวมข้อความใน `scopus_eda_analysis.py`


```
def combine_text(row):  
    parts = []  
    if row['title']:  
        parts.append(f"Title: {row['title']}")  
    if row['abstract']:  
        parts.append(f"Abstract: {row['abstract']}")  
    if row['author_keywords']:  
        parts.append(f"Author keywords: {row['author_keywords']}")  
    if row['index_keywords']:  
        parts.append(f"Index keywords: {row['index_keywords']}")  
    return '\n'.join(parts)
```

เหตุผลและความสำคัญของโครงสร้างข้อความ

- บุคลากร 4 องค์ประกอบสำคัญ: ผสาน Title, Abstract, Author Keywords และ Index Keywords เป็นประโยคเดียวที่สมบูรณ์
- Section Identifiers: ใส่แท็ก 'Title:', 'Abstract:', 'Keywords:' ชัดเจน เพื่อให้โมเดลแยกแยะบทบาทของแต่ละส่วนได้
- Semantic Enrichment: Keywords ช่วยเสริมบริบทคำศัพท์เฉพาะทาง ขณะที่ Abstract ให้รายละเอียดบริบทการทดลอง
- Consistency: รับประกันว่าข้อมูลนำเข้าของทุกบทความมีรูปแบบสม่ำเสมอสำหรับการ Tokenize

MODEL ARCHITECTURE

การจัดการข้อจำกัด 512 โทเค็นและโมเดล SPECTER2



Feature Vector Extraction Workflow

Title + Abstract + Author Keywords + Index Keywords

Structured Concatenation with Section Prefixes
Token Truncation Threshold (Max 512 Tokens)

SPECTER2 Base Model + Proximity Adapter
Dense Semantic Projection ($d = 768$)

L2 Normalization (Unit Euclidean Length: $\|v\| = 1$)
Output Feature Matrix: (6991, 768) ready for ML

ข้อจำกัด 512 Tokens & SPECTER2

- SPECTER2 Base Model: โมเดลที่เทรนด้วย Citation Graph เหมาะสำหรับงานจับคู่เอกสารทางวิทยาศาสตร์
- Max Length 512 Tokens: ความยาวเฉลี่ย 159.7 โทเค็น เกิน 512 เพียง 0.0%
- ผลกระทบจากการตัดข้อความ: Keywords อยู่ท้ายข้อความจึงอาจถูกตัดในบทความที่ Abstract ยาว แต่ Title และเนื้อหาสำคัญยังถูกแปลงเป็นเวกเตอร์ได้อย่างครบถ้วน
- Vector Dimension: ส่งออกเวกเตอร์ขนาด 768 มิติ

L2 Normalization และการนำไปใช้ใน Machine Learning

1. L2 Normalization

- ปรับขนาดเวกเตอร์ด้วยคำสั่ง:
`normalize(embeddings, norm='l2')`
- เวกเตอร์ทุกตัวมีความยาวเท่ากับ 1 (Unit Euclidean Length)
- Cosine Similarity คำนวณได้ทันทีด้วย Dot Product (เร็วกว่าเดิมมาก)

2. Subject Classification

- การจำแนกสาขาวิชาอัตโนมัติ (Supervised Learning)
- Features (X): เวกเตอร์ขนาด 768 มิติ
- Target (y): 10 สาขาวิชาใน Scopus
- โมเดลที่เหมาะสม: Logistic Regression, SVM, หรือ Multi-Layer Perceptron (MLP)

3. Clustering & Search

- Semantic Clustering (K-Means, HDBSCAN) เพื่อค้นพบกลุ่มวิจัยใหม่แบบไม่ต้องมี Label
- Semantic Recommendation ด้วย Approximate Nearest Neighbors (ANN)
- แนะนำบทความที่เนื้อหาคล้ายกัน แม้ใช้สปีชีส์เวิร์ดคนละคำ

KEY DELIVERABLES

สรุปผลสัมฤทธิ์โครงการและสิ่งที่ส่งมอบ

สรุปภาพรวมผลการดำเนินงาน

- ✓ ชุดข้อมูลวิชาการ Scopus 10 สาขา: รวบรวมข้อมูลดิบ 7,280 รายการ ผ่านการคลีนเหลือ 6,991 รายการ (ทุกสาขาเกิน 600 รายการอย่างครบถ้วน)
- ✓ สคริปต์ประมวลผล scopus_eda_analysis.py: รันการทำความสะอาด ตรวจสอบความซ้ำซ้อน สถิติเชิงพรรณนา และจำลองการสกัด Feature Vector
- ✓ เว็บไซต์ Interactive Dashboard 6 มุมมอง: Knowledge Network, Word Cloud, Overlap Heatmap, Topic Quadrant, EDA Metrics, Document Explorer
รันแบบ Offline และบน GitHub Pages ได้สมบูรณ์
- ✓ Feature Vector & ML Readiness: สร้างเวกเตอร์ขนาด (6991, 768) พร้อม L2 Normalization
- ✓ เอกสารรายงานและสไลด์สมบูรณ์: จัดทำ Report ครบ 3 ส่วนในรูปแบบ DOCX (ฟอนต์ TH Sarabun New) และ PDF พร้อมสไลด์ PPTX และ PDF

Thank You for Your Attention

ช่วงถาม-ตอบ (Q & A) และช่องทางเข้าชมผลงานออนไลน์

- Online Interactive Dashboard (GitHub Pages): เข้าถึงและทดลองใช้งานกราฟโต้ตอบแบบเรียลไทม์ได้ทันที
- สมาชิกกลุ่ม: ฉัฐวดี 67011211017 · พงศกร 67011211039 · อนรรักษ์ 67011211062 · ปกักร 67011211035
- อาจารย์ผู้สอน: ผศ.ดร.โอฬาริก สุรินตะ (วิชา EDA)